

LAPORAN PENGUJIAN DAN ANALISIS DATA

Sistem Rekomendasi Produk Berbasis Item-Based Collaborative Filtering

Studi Kasus: Toko Sinar Manis

Judul Studi	Pengembangan Sistem Rekomendasi Produk Berbasis Analisis Data terhadap Transaksi Pelanggan — Toko Sinar Manis
Platform	Laravel 12 (PHP) + Pipeline Python (pandas/numpy) + MySQL
Metode Inti	Item-Based Collaborative Filtering (IBCF) dengan metrik Dice Coefficient + Hybrid Scoring
Dokumen	Laporan Pengujian & Analisis Data
Versi	1.0

Daftar Isi

- Pendahuluan
- Teknik Analisis Data
- Teknik Pengumpulan Data
- Preprocessing Data
- Analisis (Algoritma / Metode)
- Visualisasi Data
- Hasil Analisis dan Pembahasan
- Skenario Pengujian Sistem
- Kesimpulan
- Lampiran

1. Pendahuluan

Laporan ini menjelaskan teknik analisis data yang diterapkan pada sistem rekomendasi produk Toko Sinar Manis, beserta rangkaian tahapan: pengumpulan data, preprocessing, penerapan algoritma, visualisasi, serta hasil analisis.

Sistem mempelajari pola pembelian pelanggan dari data transaksi, menghitung kemiripan antarproduk, lalu menyajikan rekomendasi personal. Implementasi utama berada pada layanan `RecommenderService` (PHP) dan mesin Collaborative Filtering Python (`python/cf/`).

Tujuan pengujian dan analisis dalam dokumen ini:

1. Menjelaskan teknik analisis data yang digunakan secara konseptual dan teknis.
2. Mendokumentasikan sumber data serta cara pengumpulannya.
3. Menjelaskan tahapan pembersihan dan transformasi data (ETL).
4. Menjabarkan algoritma/metode rekomendasi beserta rumus yang diimplementasikan.
5. Menunjukkan bentuk visualisasi hasil analisis di sisi admin dan pelanggan.
6. Menyusun kerangka hasil analisis dan skenario pengujian yang dapat diisi dengan angka aktual dari environment pengguna.

2. Teknik Analisis Data

2.1 Jenis dan Pendekatan Analisis

Teknik analisis yang digunakan adalah **analisis pola transaksi pelanggan** (*transactional / behavioral analytics*) dengan pendekatan **Collaborative Filtering**.

Aspek	Keterangan
Jenis analisis	Analisis pola pembelian bersama antarproduk
Pendekatan	Collaborative Filtering
Varian	Item-Based Collaborative Filtering (IBCF)
Representasi data	Matriks user–item biner
Metrik kemiripan	Dice Coefficient (diimplementasikan di kode)
Penyempurnaan ranking	Hybrid scoring (similarity + rating ulasan)
Evaluasi performa	Precision@K, Recall@K, F1-Score@K (K = 5)

Sistem **tidak** menggunakan Apriori/association rules, content-based filtering berbasis fitur produk, maupun matrix factorization sebagai engine utama. Filter kategori pada halaman detail produk bersifat tampilan tambahan, bukan bagian perhitungan matriks CF.

2.2 Konsep Item-Based Collaborative Filtering

Pada IBCF, kemiripan dihitung antar **item (produk)**, bukan antar user. Asumsi utamanya: jika dua produk sering dibeli oleh pelanggan yang sama, maka keduanya dianggap mirip. Ketika

seorang pelanggan membeli produk A, sistem merekomendasikan produk B yang memiliki skor kemiripan tinggi terhadap A.

Alur konseptual:

```
Transaksi selesai → Matriks User×Item → Skor kemiripan antar produk
→ Simpan product_similarity → Ranking rekomendasi per user
→ (opsional) Evaluasi Precision/Recall/F1
```

2.3 Metrik Kemiripan: Dice Coefficient

Setiap produk digambarkan sebagai himpunan user yang pernah membelinya. Untuk pasangan produk A dan B:

$$[\text{Dice}(A,B) = \frac{2 \times |A \cap B|}{|A| + |B|}]$$

di mana:

- $(|A \cap B|)$ = jumlah user yang membeli produk A dan B (*co-occurrence*),
- $(|A|)$, $(|B|)$ = jumlah user unik yang membeli masing-masing produk.

Setelah semua pasangan dihitung, skor dinormalisasi terhadap nilai maksimum sehingga skor relatif berada pada rentang mendekati $[0,1]$:

$$[\text{score}_{\text{norm}}(A,B) = \frac{\text{Dice}(A,B)}{\max(\text{Dice})}]$$

Catatan dokumentasi vs implementasi: antarmuka admin/README sering menyebut *cosine similarity*, sedangkan implementasi aktual di `RecommenderService::calculateCosineSimilarity()` dan `python/cf/similarity.py` menggunakan **Dice Coefficient**. Untuk keperluan ilmiah, laporan ini merujuk pada metrik yang benar-benar dijalankan di kode.

2.4 Hybrid Scoring

Setelah kandidat rekomendasi diperoleh dari tabel kemiripan, ranking diperhalus dengan rating ulasan:

$$[\text{hybrid} = (0.7 \times \text{similarity}) + \left(0.3 \times \frac{\text{avg_rating}}{5}\right) + \text{boost}]$$

dengan $(\text{boost} = 0.1)$ jika rata-rata rating (≥ 4.0) dan jumlah ulasan (≥ 2) ; selain itu $(\text{boost} = 0)$.

Bobot 70% similarity menjaga inti Collaborative Filtering, sementara 30% rating menggeser urutan ke produk yang lebih diterima pelanggan.

2.5 Metrik Evaluasi

Pipeline Python mengevaluasi akurasi rekomendasi menggunakan holdout sederhana:

1. Untuk setiap user dengan minimal 2 produk berbeda dalam riwayat,
2. Satu produk terakhir dijadikan *test item*, sisanya *training*,
3. Sistem mengambil Top-K rekomendasi dari produk training,
4. Dihitung:

[$\text{Precision@K} = \frac{|\text{rekomendasi} \cap \text{test}|}{K}$, $\text{Recall@K} = \frac{|\text{rekomendasi} \cap \text{test}|}{|\text{test}|}$]

[$\text{F1@K} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$]

Nilai yang dilaporkan adalah rata-rata antar user yang dievaluasi (default (K = 5)).

2.6 Ruang Lingkup Sinyal Analisis

Sinyal	Digunakan di matriks CF	Digunakan di ranking
Riwayat pembelian (transaksi selesai)	Ya (biner)	Ya
Rating/ulasan produk	Tidak	Ya (hybrid + filter)
Jumlah terjual (<code>terjual</code>)	Tidak	Ya (fallback best seller)
View produk	Tidak	Tidak
Isi keranjang	Tidak	Tidak
Kategori produk	Tidak	Hanya tampilan terkait

3. Teknik Pengumpulan Data

3.1 Sumber Data Primer: Transaksi Pembelian

Data interaksi utama dikumpulkan dari aktivitas belanja nyata maupun impor massal.

a. Transaksi langsung (online)

Pelanggan melakukan alur:

Browse produk → Keranjang → Checkout → Pembayaran (Bayar di Toko / Midtrans)

Data tersimpan pada:

Tabel	Peran
<code>transactions</code>	Header pesanan: user, tanggal, status pesanan, status pembayaran, total
<code>transaction_items</code>	Detail item: <code>id_product</code> , qty, harga satuan

Sinyal CF dibentuk dari pasangan `(id_user, id_product)` pada transaksi yang memenuhi filter status.

b. Upload data historis (admin)

Admin mengunggah file CSV/Excel transaksi melalui menu Upload. File dicatat di `data_uploads`, diproses pipeline Python, lalu dimuat ke tabel transaksi yang sama. Hash file (SHA-256) mencegah unggah ulang file identik.

3.2 Sumber Data Sekunder: Ulasan Produk

Tabel	Peran
<code>product_reviews</code>	Rating 1–5 dan komentar (satu ulasan per user per produk)

Ulasan dipakai untuk:

- hybrid scoring,
- menyaring produk dengan rating rendah (rata-rata $\leq 2,0$ dengan minimal 2 ulasan),
- ranking fallback cold-start (best seller + rating).

3.3 Data Pendukung (Tidak Masuk Matriks CF)

Tabel / entitas	Keterangan
<code>products</code> , <code>categories</code>	Katalog; filter produk aktif & stok
<code>product_views</code>	Skema tersedia, belum dipakai engine rekomendasi
<code>cart</code>	Keranjang sesi; bukan input CF
<code>users</code>	Identitas pelanggan

3.4 Data Hasil Perhitungan dan Audit

Tabel	Peran
<code>product_similarity</code>	Skor kemiripan antarproduk (hasil analisis)
<code>recommendation_logs</code>	Jejak rekomendasi yang ditampilkan ke user
<code>cf_run_logs</code>	Log eksekusi batch CF
<code>upload_logs</code>	Log baris ETL upload
<code>system_settings</code>	Flag <code>recommendation_dirty</code> setelah transaksi baru

3.5 Ringkasan Teknik Pengumpulan

Teknik	Instrumen	Output
Observasi transaksi digital	Checkout aplikasi + Midtrans	Record transaksi & item
Impor data sekunder	Template CSV/Excel admin	Dataset historis terseragamkan
Umpan balik eksplisit	Form ulasan produk	Rating & komentar
Logging sistem	Service rekomendasi & pipeline	Log evaluasi dan audit

4. Preprocessing Data

Preprocessing dijalankan terutama pada pipeline Python setelah upload:

`ingest → clean → resolve user → transform → load → (CF + evaluasi)`

4.1 Ingest (`python/pipeline/ingest.py`)

- Membaca file CSV atau Excel.
- Mendeteksi alias nama kolom secara otomatis.
- Menyiapkan pemetaan kolom ke skema standar sistem.

4.2 Cleaning (`python/pipeline/cleaner.py`)

Kegiatan pembersihan meliputi:

1. Menghapus baris kosong.
2. Validasi dan parsing tanggal (multi-format).
3. Validasi `id_product` terhadap produk aktif di database.
4. Validasi/resolusi user (`id_user` atau email).
5. Pembersihan angka qty dan harga (menghapus simbol mata uang, normalisasi desimal).
6. Mapping nilai metode pembayaran dan status pesanan ke enum sistem.
7. Deteksi duplikasi berdasarkan kunci (`user/email, tanggal, id_product, qty`).
8. Pemisahan record valid vs invalid beserta alasan error per baris.

Kolom wajib: `tanggal, id_product, qty, harga_satuan`

Kolom opsional: `email, no_hp, id_user, metode_pembayaran, status_pesanan`

4.3 Resolusi User (`user_resolver.py`)

- Mencocokkan email dengan user yang sudah ada.
- Membuat user baru bila diperlukan (untuk data historis yang belum terdaftar).

4.4 Transformasi (`transformer.py`)

Baris detail digabung menjadi transaksi berdasarkan (`id_user`, `tanggal`), kemudian dipecah kembali menjadi header transaksi + item line.

4.5 Load (`loader.py`)

Data bersih dimasukkan ke MySQL (`transactions`, `transaction_items`) dengan penanda sumber upload.

4.6 Preprocessing Khusus untuk Collaborative Filtering

Sebelum membangun matriks (jalur PHP admin “Hitung Ulang”):

1. Filter `status_pesanan = 'Selesai'`.
2. Filter `status_pembayaran = 'Dibayar'` (pada implementasi PHP).
3. Agregasi ke bentuk biner: pernah beli = 1, belum = 0 (qty tidak dipakai sebagai bobot).
4. Hanya kolom produk berstatus `aktif`.
5. Pasangan tanpa *intersection* (tidak ada user bersama) dilewati.

Catatan: jalur Python CF memfilter `status_pesanan = 'Selesai'` dan menyimpan tetangga Top-K per produk (`top_k = 20`, `min_score = 0.01`), sedangkan jalur PHP dapat menyimpan pasangan dua arah secara lebih lengkap sesuai hasil perhitungan.

5. Analisis (Algoritma / Metode)

5.1 Arsitektur Perhitungan

Terdapat dua jalur perhitungan kemiripan yang bermuara pada tabel `product_similarity` :

Jalur	Pemicu	Komponen
PHP runtime	Tombol Hitung Ulang di Admin → Analisis	<code>SimilarityController</code> → <code>RecommenderService</code>
Python batch	Setelah upload CSV/Excel sukses	<code>pipeline_runner</code> → <code>batch_runner</code> → <code>cf_engine</code>

Serving rekomendasi ke pelanggan selalu melalui `RecommenderService` (PHP), membaca skor yang sudah tersimpan.

5.2 Tahap 1 — Membangun User–Item Matrix

Method: `buildUserItemMatrix()`

1. Join `transactions` dengan `transaction_items`.
2. Ambil pasangan user–produk unik pada transaksi valid.
3. Bentuk matriks biner `user × product`.

Contoh ilustratif:

User	Produk A	Produk B	Produk C
U1	1	1	0
U2	1	0	1
U3	0	1	1

5.3 Tahap 2 — Menghitung Dice Similarity

Method PHP: `calculateCosineSimilarity()` (nama historis; isi = Dice)

Fungsi Python: `compute_dice_similarity()`

Langkah:

1. Bangun himpunan pembeli per produk.
2. Untuk setiap pasangan produk ((A,B)): - hitung intersection, - hitung Dice, - simpan juga `co_occurrence`.
3. Normalisasi skor terhadap nilai Dice maksimum.
4. Simpan ke `product_similarity` (pasangan A→B dan B→A pada jalur PHP).

5.4 Tahap 3 — Generate Rekomendasi Personal

Method: `recommendForCustomer()` / `getFullRecommendation()`

1. Ambil produk yang pernah dibeli user.
2. Jika riwayat kosong → **cold start** (fallback).
3. Query tetangga dari `product_similarity` untuk produk yang dibeli.
4. Exclude produk yang sudah dibeli dan produk rating rendah.
5. Filter produk aktif dan stok > 0.
6. Terapkan hybrid scoring; urutkan menurun.
7. Catat ke `recommendation_logs`.
8. Susun alasan tampilan, misalnya: “*Sering dibeli bersama {nama produk}*”.

5.5 Tahap 4 — Fallback Cascade

Jika hasil CF kosong atau tidak memadai:

1. **Buy Again** — produk yang sering dibeli user sebelumnya.
2. **Best Seller + Rating** — skor gabungan:
$$\left[(0,6 \times \frac{\text{avg_rating}}{5}) + (0,4 \times \frac{\text{terjual}}{\text{max_terjual}}) \right]$$
3. **Produk tersedia** — produk aktif berstok, diurut terbaru.

5.6 Rekomendasi Produk Serupa

Pada halaman detail produk, sistem mencari `product_b` dengan `product_a` = produk yang sedang dilihat, diurutkan berdasarkan skor kemiripan dan co-occurrence. Ini memanfaatkan hasil IBCF yang sama.

5.7 Evaluasi Batch (Python)

`python/cf/evaluator.py` menghitung `Precision@5`, `Recall@5`, dan `F1@5` setelah matriks kemiripan tersedia. Hasil evaluasi dapat dipakai sebagai indikator kuantitatif pada subbab hasil analisis.

5.8 Ringkasan Komponen Kode

File	Fungsi
<code>app/Services/RecommenderService.php</code>	Matrix, Dice, hybrid, fallback, logging
<code>app/Http/Controllers/Api/SimilarityController.php</code>	Endpoint hitung ulang
<code>app/Http/Controllers/Admin/AnalisisController.php</code>	Data dashboard analisis
<code>python/cf/similarity.py</code>	Dice + co-occurrence (numpy)
<code>python/cf/cf_engine.py</code>	Persistensi hasil CF
<code>python/cf/evaluator.py</code>	Precision/Recall/F1
<code>python/pipeline/*</code>	ETL upload transaksi

6. Visualisasi Data

6.1 Dashboard Analisis Admin (`/admin/analisis`)

Halaman ini menjadi pusat visualisasi hasil Collaborative Filtering, antara lain:

1. Kartu statistik (jumlah pasangan similarity, coverage, ringkasan run).
2. **Grafik distribusi skor** (`Chart.js` — bar chart) untuk melihat sebaran nilai kemiripan.

3. Tabel Top produk yang sering muncul di rekomendasi.
4. Riwayat eksekusi CF (`cf_run_logs`).
5. Tabel pasangan produk mirip (`product_a`, `product_b`, `score`, `co-occurrence`).
6. Log rekomendasi harian.
7. Tombol **Hitung Ulang** untuk menjalankan ulang perhitungan PHP.

6.2 Visualisasi Lain di Admin

Halaman	Visualisasi
<code>/admin/dashboard</code>	Grafik transaksi/pendapatan bulanan; popularitas kategori
<code>/admin/reviews</code>	Distribusi rating bintang 1–5 (Chart.js)
<code>/admin/laporan</code>	Laporan transaksi dengan filter tanggal
<code>/admin/upload</code>	Status progress pipeline ETL + CF

6.3 Visualisasi / Presentasi di Sisi Pelanggan

Halaman	Bentuk penyajian hasil analisis
<code>/rekomendasi</code>	Kartu rekomendasi personal + badge metode + alasan
Detail produk	Bagian “Produk Serupa” berbasis similarity
Beranda	Penjelasan singkat mekanisme rekomendasi (edukatif)

6.4 API Pendukung

Endpoint	Fungsi
GET <code>/api/rekomendasi?action=personal\ similar\ popular</code>	Data rekomendasi JSON
POST <code>/admin/similarity</code>	Trigger perhitungan ulang
GET <code>/admin/pipeline-status</code>	Status pipeline upload

Visualisasi bersifat *dashboard analytics* untuk admin dan *recommendation UI* untuk pelanggan; keduanya menggunakan hasil analisis yang sama dari `product_similarity`.

7. Hasil Analisis dan Pembahasan

Subbab ini menyediakan kerangka hasil. **Isi angka aktual** setelah menjalankan perhitungan CF pada dataset environment Anda (Admin → Analisis / setelah upload pipeline).

7.1 Ringkasan Dataset Uji

Parameter	Nilai (isi hasil aktual)
Jumlah transaksi selesai	...
Jumlah user dengan riwayat beli	...
Jumlah produk aktif	...
Jumlah pasangan di <code>product_similarity</code>	...
Coverage matriks / produk berkoneksi	... %
Tanggal terakhir hitung ulang CF	...

7.2 Hasil Perhitungan Kemiripan

Temuan yang diharapkan untuk dibahas:

1. Distribusi skor (dari grafik admin): apakah mayoritas pasangan lemah, sedang, atau kuat.
2. Contoh pasangan produk dengan skor tertinggi dan interpretasi bisnis (apakah masuk akal dibeli bersama).
3. Peran `co_occurrence` sebagai bukti frekuensi pembelian bersama.

Contoh tabel hasil (template):

Produk A	Produk B	Score	Co-occurrence	Interpretasi singkat
...	...	...	...	Sering dibeli bersama
...	...	...	...	...

7.3 Hasil Evaluasi Kuantitatif

Ambil dari output evaluator / log CF:

Metrik	Nilai
Precision@5	...
Recall@5	...
F1-Score@5	...
Jumlah user dievaluasi	...

Pembahasan singkat yang disarankan:

- Precision rendah dapat terjadi jika katalog besar dan Top-5 jarang mengenai tepat satu *holdout item*.

- Recall@5 pada skema holdout 1 item bernilai 0 atau 1 per user; rata-rata mencerminkan proporsi user yang “terkena” rekomendasi.
- F1 menyeimbangkan keduanya sebagai ringkasan tunggal.

7.4 Hasil Uji Fungsional Rekomendasi

Kondisi user	Perilaku sistem yang diamati	Sumber rekomendasi
Memiliki riwayat transaksi selesai	Muncul rekomendasi personal + alasan	CF + hybrid
Belum pernah beli / guest	Muncul produk populer / best seller	Fallback
Membuka detail produk	Muncul produk serupa	Similarity item
Produk stok habis / nonaktif	Tidak ditampilkan	Filter stok & status

7.5 Pembahasan Kelebihan dan Keterbatasan

Kelebihan

1. Memanfaatkan data transaksi riil (implisit), tidak bergantung pada pengisian profil.
2. Hybrid scoring mengurangi risiko merekomendasikan produk mirip tetapi berkualitas rendah.
3. Ada jalur batch (Python) untuk data besar dan jalur manual (PHP) untuk hitung ulang cepat.
4. Tersedia logging dan dashboard analisis untuk audit hasil.

Keterbatasan

1. Cold-start user baru belum bisa dipersonalisasi penuh tanpa riwayat.
2. Produk baru yang jarang dibeli sulit mendapat tetangga similarity.
3. Matriks biner mengabaikan intensitas qty/frekuensi sebagai bobot.
4. View produk belum dimanfaatkan sebagai sinyal minat.
5. Perbedaan filter status antara PHP dan Python perlu diperhatikan saat membandingkan hasil.

7.6 Implikasi untuk Toko Sinar Manis

Hasil analisis kemiripan dapat dipakai untuk:

- menata *cross-selling* di kasir/online,
 - menyusun bundling produk yang sering dibeli bersama,
 - memantau produk yang sering direkomendasikan tetapi stoknya menipis,
 - mengevaluasi ulang katalog yang jarang muncul di tetangga similarity.
-

8. Skenario Pengujian Sistem

8.1 Pengujian Black-Box

ID	Skenario	Langkah	Hasil yang diharapkan
Uji-01	Hitung ulang similarity	Login admin → Analisis → Hitung Ulang	<code>product_similarity</code> terisi; statistik terbaru
Uji-02	Upload transaksi	Upload CSV valid → pantau pipeline	Transaksi masuk; CF batch jalan; log sukses
Uji-03	Upload data kotor	Upload CSV dengan tanggal/produk invalid	Baris invalid ditolak; tercatat di <code>upload_logs</code>
Uji-04	Rekomendasi user berriwayat	Login pelanggan yang punya transaksi selesai → <code>/rekomendasi</code>	Muncul rekomendasi CF + alasan
Uji-05	Cold start	Login user tanpa transaksi → <code>/rekomendasi</code>	Fallback best seller / produk tersedia
Uji-06	Produk serupa	Buka detail produk yang punya tetangga	Section produk serupa tampil
Uji-07	Filter stok	Habiskan stok produk rekomendasi	Produk tidak muncul di rekomendasi
Uji-08	Rating rendah	Beri ≥ 2 ulasan dengan rata-rata ≤ 2 pada suatu produk	Produk tersaring dari kandidat
Uji-09	Log rekomendasi	Tampilkan rekomendasi lalu cek admin/analisis	Ada entri <code>recommendation_logs</code>
Uji-10	Evaluasi metrik	Jalankan CF Python + evaluator	Tercatat Precision/Recall/F1

8.2 Pengujian Validasi Rumus (Sampel Manual)

Untuk satu pasangan produk A dan B:

1. Hitung manual jumlah pembeli A, B, dan irisan dari database.
2. Hitung Dice manual.
3. Bandingkan dengan nilai di `product_similarity` (perhatikan normalisasi terhadap max).

Template:

Item	Nilai
A	...
B	...
A ∩ B	...
Dice mentah	...
Score tersimpan (setelah normalisasi)	...
Sesuai?	Ya / Tidak

8.3 Kriteria Keberhasilan Pengujian

Pengujian dianggap berhasil jika:

1. Pipeline ETL menolak data invalid dan menerima data valid.
2. Perhitungan similarity menghasilkan pasangan dengan `score > 0` dan `co_occurrence ≥ 1`.
3. Halaman rekomendasi menampilkan sumber yang konsisten (CF atau fallback).
4. Dashboard analisis menampilkan grafik dan tabel tanpa error.
5. Metrik evaluasi dapat dihasilkan ulang setelah batch CF.

9. Kesimpulan

1. Teknik analisis data pada sistem Toko Sinar Manis adalah **Item-Based Collaborative Filtering** atas data transaksi, dengan metrik **Dice Coefficient**, diperkuat **hybrid scoring** berbasis rating.
2. Pengumpulan data mengandalkan transaksi online, impor CSV/Excel, dan ulasan produk; sinyal utama CF adalah pembelian implisit biner.
3. Preprocessing dilakukan melalui pipeline ETL Python (validasi, cleaning, resolusi user, transformasi, load) serta filter status transaksi sebelum pembentukan matriks.
4. Analisis dijalankan dalam dua jalur (PHP dan Python) yang menyimpan hasil ke `product_similarity`, lalu disajikan sebagai rekomendasi personal dan produk serupa.
5. Visualisasi hasil tersedia di dashboard admin (distribusi skor, statistik CF, log) dan antarmuka pelanggan (daftar rekomendasi serta alasan).
6. Hasil analisis kuantitatif (Precision/Recall/F1) dan kualitatif (contoh pasangan produk, perilaku cold-start) dilengkapi melalui skenario pengujian pada Bab 8 dan diisi dengan data aktual dari environment produksi/pengujian.

10. Lampiran

Lampiran A — Rumus Ringkas

Dice Similarity

[$\text{Dice}(A,B)=\frac{2|A\cap B|}{|A|+|B|}$]

Hybrid Score

[$\text{hybrid}=0,7\cdot \text{sim}+0,3\cdot \frac{\text{bar}\{r\}}{5}+ \begin{cases} 0,1 & \text{jika} \\ \text{bar}\{r\}\geq 4 \end{cases} \text{ dan } \begin{cases} 0 & \text{dan } n\geq 2 \\ 0 & \text{lainnya} \end{cases}$]

Best Seller Fallback

[$\text{score}=0,6\cdot \frac{\text{bar}\{r\}}{5}+0,4\cdot \frac{\text{terjual}}{\max(\text{terjual})}$]

Lampiran B — Struktur Tabel Inti

- users
- products , categories
- transactions , transaction_items
- product_reviews
- product_similarity
- recommendation_logs
- data_uploads , upload_logs
- cf_run_logs

Lampiran C — File Implementasi Utama

- app/Services/RecommenderService.php
- app/Http/Controllers/Api/SimilarityController.php
- app/Http/Controllers/Admin/AnalisisController.php
- app/Http/Controllers/RekomendasiController.php
- python/pipeline/pipeline_runner.py
- python/pipeline/cleaner.py
- python/cf/similarity.py
- python/cf/cf_engine.py
- python/cf/evaluator.py
- resources/views/admin/analisis.blade.php
- resources/views/customer/rekomendasi.blade.php

Lampiran D — Cara Mengisi Angka Hasil Aktual

1. Pastikan ada transaksi dengan status selesai (dan dibayar untuk jalur PHP).
2. Jalankan **Hitung Ulang** di `/admin/analisis` atau upload CSV hingga pipeline selesai.
3. Catat statistik di halaman analisis (pasangan, coverage, distribusi skor).
4. Ambil Precision@5, Recall@5, F1@5 dari log CF / output evaluator.
5. Salin contoh Top pasangan similarity ke tabel Bab 7.
6. Lakukan skenario Uji-04 s.d. Uji-06 dan lampirkan screenshot.

Lampiran E — Glosarium Singkat

Istilah	Arti
IBCF	Item-Based Collaborative Filtering
Cold start	Kondisi user/produk tanpa cukup riwayat
Co-occurrence	Jumlah user yang membeli dua produk sekaligus
Holdout	Data uji yang disisihkan untuk evaluasi
ETL	Extract, Transform, Load
Hybrid scoring	Penggabungan skor similarity dan rating

Dokumen ini disusun berdasarkan implementasi kode pada repositori sistem rekomendasi produk Toko Sinar Manis (Laravel + Python CF). Angka hasil evaluasi pada Bab 7 perlu dilengkapi dari environment pengujian pengguna.